


Uczenie ze wzmocnieniem

Problem odwróconego wahadła




Wprowadzenie

Zagadnienie odwróconego wahadła jest akademicki przykładem, rozważań sterowania w przestrzeni stanów. W klasycznym podejściu często korzysta się z odpowiednio dostrojonego sterownika PID, którego wzmocnienia zostają wyliczone m.in. na podstawie wyprowadzeń zależności fizycznych. W nowoczesnych metodach sterowania do rozwiązania danego zagadnienia wykorzystuje się algorytmy genetyczne, logikę rozmytą czy też sztuczne sieci neuronowe. W rozważaniach został przyjęty model odwróconego wahadła matematycznego zaimplementowany z biblioteki "gym" w środowisku Phyton. Celem projektu było ustabilizowanie wahadła z wykorzystaniem sieci neuronowej.

Opis


W celu realizacji projektu za pomocą sztucznej sieci neuronowej można przyjąć różne podejścia realizujące dane zagadnienie. Pierwszym z nich jest wykorzystanie pętli sprzężenia zwrotnego, w której to za pomocą algorytmu bionicznego staramy przewidzieć

uchyb układu a następnie poddać go kompensacji. W kolejnym podejściu sztuczna sieć neuronowa odpowiada za zmianę nastaw sterownika PID. W danym projekcie przyjęto, iż algorytm ma na celu dokonać predykcji kolejnych ruchów wózka, przez co zastępuje on algorytm PID. Jako algorytm uczący został wykorzystany algorytm propagacji wstecznej błędu. Algorytm waży kolejne wejścia a następnie poddaje je działaniu funkcji aktywacji, w projekcie została przyjęta sigmoida. W kolejnych krokach odbywa się sumacja wejść na każdy neuron oraz następnie sygnał zostaje podany w analogiczny sposób na wyjście. Po wielokrotnych symulacjach została przyjęta struktura sieci wykorzystująca jedynie dwie warstwy sieci, pierwsza warstwa sieci zawiera jedynie 16 neuronów. Sieci z jedną warstwą ukrytą oraz zbudowane z większej ilości neuronów, osiągały gorsze wyniki podczas sterowania wahadłem. Algorytm propagacji wstecznej błędu polega na zmianie wag wykorzystując przepływ błędu w sieci w kierunku odwrotnym do propagacji sygnału pobudzającego, zgodnie ze schematem zamieszczonym na rys. 1. Dzięki takiemu podejściu, podczas nauczania każdorazowo zostaje wprowadzona poprawka na wagi w poszczególnych warstwach sieci realizowana przy pomocy algorytmu zamieszczonego na rys. 2. Przy czym należy uwzględnić wpływ pochodnych funkcji pobudzenia neuronów.



Rys. 1 Zasada propagacji wstecznej błędu¹

¹ Źródło: Ryszard Tadeusiewicz "Sieci neuronowe", Kraków 1992




Rys. 2 Zmiana wartości wag²

W celu nauczania sieci przyjęto dwie wartości wejściowe. Pierwsza z nich przyjmuje wartość kąta odchylenia wahadła z zakresu $-15^\circ - 15^\circ$, druga prędkość kątową z zakresu $-\infty - +\infty$. Podczas nauczania przyjęto nadrzędność wpływu wartości kątowej nad miarą kąta odchylenia. Następnie podano wektor wzorcowy odpowiedzi. Nauczanie sieci odbywa się poprzez 2000 krotne wywołanie algorytmu propagacji wstecznej błędu.

Obserwacje

Tak skonstruowana sieć pozwala na utrzymanie wahadła w równowadze przez 200s, co jest wartością ogólnie zadeklarowaną w bibliotece gym, powodującą reset gry. Czasy krótsze niż 200s zazwyczaj spowodowane są opuszczeniem przez wózek pola widzenia, co również resetuje bibliotek. Obserwację działania algorytmu przedstawiono na rys. 3.

² Źródło: Ryszard Tadeusiewicz "Sieci neuronowe", Kraków 1992



Rys. 3 Symulacje pracy algorytmu

Po wielokrotnych symulacjach sieci neuronowej zostały zaobserwowane 4 typy zachowań podczas odpowiedzi układu. Typ pierwszy i drugi obrazuje wykres pierwszy z rys. 3, są to najczęściej uzyskiwane wyniki. W pierwszym przypadku układ jest idealnie stabilny, wózek nie przemieszcza się, natomiast w drugim wózek stosunkowo dynamicznie zmienia swoje położenie. Na drugim wykresie została przedstawiona sytuacja pełnej stabilizacji wahadła, jednakże wózek ucieka z pola widzenia, powodując reset układu. Ostatni wykres pokazuje skrajną sytuację złego wyuczenia sieci.

Wnioski:

Dzięki wykorzystaniu losowych zmiennych uczących, realizacja projektu wyraźnie pokazała problem związany z zagadnieniem nauczania sztucznej sieci neuronowej. Nie każdy zestaw danych wejściowych pozwala uzyskać algorytm optymalny w sterowaniu przy skorzystaniu z danej struktury sieci. Dlatego też w realizacjach praktycznych niejednokrotnie wykorzystuje się algorytmy genetyczne mające na celu optymalizację budowy sztucznej sieci neuronowej.

Realizacja:

Marcin Januszewicz 160622

Jan Glinko 161259

Michał Topka 160836

Dawid Łukaszewski 160539
